


Epigenómica y regulación



La naturaleza combinatoria de las modificaciones de los extremos amino de las histonas revela así un “código de histonas” que amplía considerablemente el potencial informativo del código genético.

— Jenuwein y Allis (2001)

● Al terminar este capítulo usted podrá

- Describir la organización de la cromatina (nucleosomas, marcas de histonas, estados de cromatina) y los grandes atlas epigenómicos (ENCODE, Roadmap Epigenomics).
- Explicar la geometría de las lecturas de ChIP-seq, estimar el tamaño de fragmento por correlación cruzada y llamar picos con el modelo de Poisson local de MACS; evaluar un experimento con FRiP, NSC/RSC, IDR y la lista negra.
- Interpretar la distribución de tamaños de fragmento y el enriquecimiento en TSS de un experimento de ATAC-seq.
- Deducir la química de la conversión por bisulfito, alinear lecturas convertidas y cuantificar la metilación con valores β y M ; detectar regiones diferencialmente metiladas con modelos beta-binomiales.

- Formular el descubrimiento de motivos como un problema de datos incompletos y resolverlo con el algoritmo EM (MEME) y con muestreo de Gibbs; evaluar motivos por enriquecimiento diferencial y centralidad.

Todas las células de un organismo llevan, salvo excepciones, el mismo genoma. Una neurona y un linfocito leen, sin embargo, capítulos muy distintos de ese texto común: la primera expresa canales iónicos y receptores de neurotransmisores; el segundo, receptores de antígenos y citocinas. La diferencia no está en la secuencia sino en *cómo se lee*: qué regiones están accesibles a la maquinaria de transcripción, qué factores de transcripción se unen a ellas, qué marcas químicas llevan las histonas que empaquetan el ADN y qué citosinas están metiladas. Ese conjunto de estados, heredable a través de las divisiones celulares pero reversible, es el *epigenoma*, y la *epigenómica* es el intento de medirlo a escala de genoma completo.

La secuenciación masiva convirtió la epigenómica en una disciplina cuantitativa: casi todas sus técnicas terminan en millones de lecturas cortas que se mapean contra la referencia (??) y cuyo patrón de acumulación hay que interpretar estadísticamente. En este capítulo recorreremos las tres preguntas centrales del área. Primero, *¿dónde* se une una proteína o dónde está abierta la cromatina? Lo responden ChIP-seq y ATAC-seq, y la herramienta matemática será el modelo de Poisson para distinguir un pico de un fondo (sección 13.1). Segundo, *¿qué* citosinas están metiladas y cuánto? Lo responde la secuenciación con bisulfito, y la herramienta será el modelo beta-binomial (sección 13.2). Tercero, *¿por qué* se une un factor allí y no en otro lugar? Lo responde el descubrimiento de motivos, que retoma las matrices de peso posicional del ?? y las aprende de los datos con los algoritmos EM y de Gibbs (sección 13.3).

13.1 ChIP-seq y ATAC-seq

 Colab · 13.1 · ChIP-seq y ATAC-seq

 repositorio del curso

Huellas en la nieve

Imagine que quiere saber dónde se detienen los ciervos en un bosque nevado, pero nunca los ve: solo encuentra huellas al amanecer. Si caminara al azar por el bosque, vería huellas dispersas por todas partes; pero alrededor de los comederos las huellas se amontonan, llegan desde el norte por un lado y se

van hacia el sur por el otro. Para decidir si un amontonamiento es un comedero o una casualidad necesita saber cuántas huellas *esperaría* en esa zona si los ciervos pasearan sin rumbo (el fondo), y ese fondo no es igual en todo el bosque: junto al arroyo siempre hay más tránsito. ChIP-seq es exactamente esto. Las lecturas son huellas de fragmentos de ADN que estuvieron unidos a una proteína; se amontonan alrededor del sitio de unión, llegan por la hebra + desde un lado y por la hebra – desde el otro, y la estadística consiste en compararlas con un fondo local bien estimado.

13.1.1 La cromatina: un genoma empaquetado

El ADN de una célula humana mide unos dos metros y cabe en un núcleo de pocas micras. Lo consigue enrollándose alrededor de octámeros de histonas (dos copias de cada una de H2A, H2B, H3 y H4). Cada unidad, el *nucleosoma*, envuelve unos 147 pares de bases en una superhélice de casi dos vueltas; la estructura cristalográfica de Luger et al. (1997) mostró en detalle atómico cómo 146 pares de bases se organizan alrededor del octámero y cómo las colas amino-terminales de las histonas salen entre las vueltas del ADN para contactar con partículas vecinas. Entre un nucleosoma y el siguiente queda un segmento de ADN *conector* (*linker*) de longitud variable, de modo que la repetición nucleosomal típica es de unos 180 a 200 pb. Esta cifra reaparecerá, como una huella dactilar, en los datos de ATAC-seq.

Las colas de las histonas son el soporte de un rico repertorio de modificaciones postraduccionales: acetilación, metilación (mono-, di- o tri-), fosforilación, ubiquitinación. Se nombran con una notación compacta: H3K27ac es la acetilación de la lisina 27 de la histona H3; H3K4me3, la trimetilación de la lisina 4. Jenuwein y Allis (2001) propusieron que la combinación de marcas forma un *código de histonas* que, leído por proteínas con dominios específicos, determina transiciones entre cromatina activa y silenciada. La tabla 13.1 resume las marcas más estudiadas.

Tres grandes consorcios han cartografiado estas marcas junto con la unión de factores de transcripción y la accesibilidad de la cromatina. El proyecto ENCODE (*Encyclopedia of DNA Elements*) publicó en 2012 un mapa integrado de transcripción, unión de factores, estructura de la cromatina y modificación de histonas en líneas celulares humanas, y afirmó poder asignar alguna “función bioquímica” al 80 % del genoma (ENCODE Project Consortium, 2012). La cifra provocó un intenso debate, porque actividad bioquímica no equivale a función biológica; la lección metodológica es que *toda señal epigenómica es una medida, no una interpretación*. La tercera fase del proyecto amplió la enciclopedia a humano y ratón y organizó

Tabla 13.1. Marcas de histonas más usadas en los atlas epigenómicos, con su localización típica y la forma de su señal en ChIP-seq. Las marcas “anchas” cubren decenas de kilobases y requieren estrategias de llamada distintas de las de un factor de transcripción.

Marca	Dónde aparece	Asociación	Señal
H3K4me3	promotores, alrededor del TSS	activa	estrecha
H3K4me1	potenciadores (<i>enhancers</i>) activos o preparados	activa/latente	intermedia
H3K27ac	potenciadores y promotores activos	activa	intermedia
H3K36me3	cuerpos de genes transcritos	elongación	ancha
H3K27me3	genes reprimidos por Polycomb	represiva	ancha
H3K9me3	heterocromatina constitutiva, repeticiones	represiva	ancha

los datos en un registro de elementos candidatos *cis*-reguladores (ENCODE Project Consortium et al., 2020). En paralelo, el consorcio Roadmap Epigenomics generó 111 epigenomas de referencia de tejidos y tipos celulares primarios e integró cinco marcas centrales (H3K4me3, H3K4me1, H3K36me3, H3K27me3 y H3K9me3) en un modelo de *estados de cromatina* con el que anotar cada segmento del genoma como promotor activo, potenciador, región transcrita, región reprimida por Polycomb o heterocromatina (Roadmap Epigenomics Consortium et al., 2015).

13.1.2 El experimento de ChIP-seq

La inmunoprecipitación de cromatina seguida de secuenciación (ChIP-seq) mide dónde está una proteína en el genoma de una población de células. Johnson et al. (2007) la usaron para mapear la unión del represor NRSF (también llamado REST) a 1946 sitios del genoma humano, con una resolución de unas ± 50 pb, lo bastante fina para descubrir variantes no canónicas de su motivo. El protocolo tiene cinco pasos (figura 13.1):

1. **Entrecruzamiento.** El formaldehído forma enlaces covalentes entre proteínas y ADN cercanos, “congelando” las interacciones del momento.
2. **Fragmentación.** La cromatina se rompe por sonicación (o con nucleasa) en fragmentos de unos 100 a 300 pb.
3. **Inmunoprecipitación.** Un anticuerpo específico contra la proteína (o contra una marca de histona) captura los fragmentos que la llevan; el resto se lava.



Figura 13.1. Flujo de un experimento de ChIP-seq. (1) El formaldehído fija el factor de transcripción (naranja) a su sitio; los nucleosomas (gris) también quedan fijados. (2) La cromatina se fragmenta. (3) Un anticuerpo acoplado a una esfera magnética captura los fragmentos con el factor; los demás se descartan. (4) Tras purificar el ADN se secuencian los extremos 5' de cada fragmento: si se lee la hebra superior, el extremo 5' está a la izquierda del sitio; si se lee la inferior, a la derecha. (5) Al mapear, las lecturas + (azul) se acumulan a la izquierda del sitio y las - (rojo) a la derecha: la firma geométrica de un sitio de unión verdadero.

- 4. Reversión y secuenciación.** Se revierte el entrecruzamiento, se purifica el ADN, se prepara una biblioteca y se secuencian, casi siempre solo por un extremo de cada fragmento o en pares cortos.
- 5. Mapeo.** Las lecturas se alinean a la referencia (??) y se buscan regiones con más lecturas de las esperadas: los *picos*.

Siempre se acompaña de un *control*: normalmente el *input*, ADN fragmentado de la misma muestra pero sin inmunoprecipitar, que registra los sesgos que nada tienen que ver con la proteína (regiones más fáciles de sonicar, amplificaciones del número de copias, zonas de mapeo problemático). Park (2009) ofrece una revisión clásica de las ventajas de ChIP-seq frente a su predecesor en micromatrices (ChIP-chip) y de los retos de diseño y análisis.

13.1.3 La geometría de las lecturas: dos hebras y un desplazamiento

El detalle clave del paso 4 es que la secuenciación lee solo las primeras decenas de bases de cada fragmento, desde su extremo 5'. Si el fragmento tiene longitud ℓ y está centrado en el sitio de unión μ , la lectura de la hebra + empieza en $\mu - \ell/2$ y la de la hebra - en $\mu + \ell/2$. Con muchos fragmentos, las lecturas de cada hebra forman una “montaña” desplazada del sitio.

Teorema 13.1. (Perfiles esperados por hebra)

Sea c la posición del centro de un fragmento, con densidad $\varphi(c)$ centrada en el sitio μ , y sea ℓ su longitud, independiente de c , con densidad $g(\ell)$. Las densidades esperadas de extremos 5' en cada hebra son

$$f_+(x) = \int g(\ell) \varphi\left(x + \frac{\ell}{2}\right) d\ell, \quad f_-(x) = \int g(\ell) \varphi\left(x - \frac{\ell}{2}\right) d\ell. \quad (13.1)$$

Si φ es simétrica alrededor de μ , f_+ y f_- son imágenes especulares una de otra y sus centros de masa están en $\mu \mp \bar{\ell}/2$; la distancia entre ambos es la longitud media del fragmento, $d = \bar{\ell}$.

DONDE

μ	Posición del sitio de unión en el genoma.
$\varphi(c)$	Densidad de la posición del centro del fragmento; su anchura refleja la imprecisión de la fragmentación.
$g(\ell), \bar{\ell}$	Densidad y media de la longitud de los fragmentos de la biblioteca.
$f_{\pm}(x)$	Densidad esperada de extremos 5' de lecturas en la hebra + o – en la posición x .
d	Desplazamiento entre las dos montañas; se estima de los datos y se usa para “centrar” las lecturas.

La demostración es un cambio de variable: una lectura + cae en x si el fragmento tiene centro $c = x + \ell/2$, de modo que basta integrar sobre las longitudes posibles. El resultado tiene una consecuencia práctica inmediata. Si desplazamos cada lectura + una distancia $d/2$ hacia la derecha y cada lectura – una distancia $d/2$ hacia la izquierda, las dos montañas se superponen en el sitio verdadero y la resolución mejora. Alternativamente, se puede *extender* cada lectura hasta la longitud d en dirección 3', reconstruyendo el fragmento completo; la suma de fragmentos reconstruidos se llama *pileup*. MACS estima d tomando las regiones más enriquecidas, separando sus lecturas por hebra y midiendo la distancia entre las modas de ambas (Zhang et al., 2008). La figura 13.2 (a) muestra el resultado con fragmentos simulados de longitud media 200 pb: las modas están en -100 y $+99$, y la suma desplazada queda centrada en el sitio.

13.1.4 Correlación cruzada entre hebras

Una estimación de d que no requiere elegir regiones de antemano usa *todo* el genoma. Sean $n_+(x)$ y $n_-(x)$ los conteos de extremos 5' en cada posición. Si los sitios de unión dominan la señal, n_- se parece a n_+ desplazado d posiciones, y la correlación entre ambos perfiles será máxima en ese desplazamiento (Kharchenko et al., 2008).

Definición 13.1. (Correlación cruzada entre hebras)

Para cada desplazamiento $s \geq 0$,

$$r(s) = \text{corr}(n_+(x), n_-(x+s)) = \frac{\sum_x (n_+(x) - \bar{n}_+)(n_-(x+s) - \bar{n}_-)}{(G-s)\sigma_+\sigma_-}, \quad (13.2)$$

donde la suma recorre las $G-s$ posiciones válidas del genoma. El *tamaño de fragmento estimado* es $\hat{d} = \arg \max_s r(s)$, excluyendo desplazamientos cercanos a la longitud de lectura.

DONDE

$n_{\pm}(x)$	Número de lecturas cuyo extremo 5' cae en x en cada hebra.
$\bar{n}_{\pm}, \sigma_{\pm}$	Media y desviación estándar de esos conteos a lo largo del genoma.
G	Longitud del genoma (o del cromosoma analizado).
s	Desplazamiento aplicado a la hebra $-$.

La curva $r(s)$ tiene casi siempre *dos* máximos. El primero, en $s = \hat{d}$, es la señal biológica. El segundo, en $s \approx L$ (la longitud de lectura), es el *pico fantasma* (*phantom peak*), un artefacto de la mapeabilidad: en regiones repetidas, donde las lecturas no pueden mapearse de forma única, desaparecen a la vez las lecturas $+$ que empiezan en x y las lecturas $-$ cuyo extremo 5' está en $x + L - 1$, lo que correlaciona ambas hebras a esa distancia aunque no haya proteína alguna. Las guías de ENCODE y modENCODE (Landt et al., 2012) convirtieron la curva en dos índices de calidad:

$$\text{NSC} = \frac{r(\hat{d})}{\min_s r(s)}, \quad \text{RSC} = \frac{r(\hat{d}) - \min_s r(s)}{r(L) - \min_s r(s)}. \quad (13.3)$$




Figura 13.2. (a) Densidad de extremos 5' de 4000 fragmentos simulados alrededor de un sitio de unión (longitud media 200 pb). Las lecturas de la hebra + (azul) forman una montaña a la izquierda del sitio y las de la hebra – (rojo), su imagen especular a la derecha (ecuación (13.1)); al desplazarlas $d/2$ hacia el centro (línea discontinua) se superponen sobre el sitio. (b) Correlación cruzada entre hebras (ecuación (13.2)) en un cromosoma simulado de 3 Mb con regiones no mapeables. La muestra buena muestra un máximo claro en el tamaño de fragmento y un pico fantasma menor en la longitud de lectura ($L = 36$); en la muestra pobre el pico fantasma domina, señal de que el anticuerpo apenas enriqueció. Datos: `figuras/cap13/generar.py`.

DONDE

NSC	Coefficiente de hebras normalizado: cuánto sobresale el pico de fragmento sobre el fondo de la curva.
RSC	Coefficiente de hebras relativo: tamaño del pico de fragmento comparado con el del pico fantasma.
L	Longitud de las lecturas.

Un RSC mayor que 1 indica que la señal biológica domina sobre el artefacto de mapeo; según esas guías, valores de NSC por debajo de 1,05 y de RSC por debajo de 0,8 delatan un enriquecimiento pobre. En la simulación de la figura 13.2 (b), con lecturas de 36 pb, la muestra buena alcanza su máximo en $\hat{d} = 176$ pb con NSC = 2,70 y RSC = 1,76; en la muestra pobre, con siete veces menos lecturas procedentes de sitios reales, el pico de fragmento casi desaparece y el máximo fuera de la zona del fantasma cae en un desplazamiento de 104 pb sin significado biológico, con RSC = 0,36.

13.1.5 Llamar picos: el fondo de Poisson local

Una vez desplazadas las lecturas, la pregunta es estadística: ¿en qué ventanas del genoma hay *más* lecturas de las que produciría el fondo? El modelo más simple supone que, en ausencia de unión, las N lecturas se reparten uniformemente sobre las G posiciones mapeables.

Teorema 13.2. (*Conteo en una ventana bajo el fondo uniforme*)

Si cada una de las N lecturas cae en una ventana de ancho w con probabilidad $p = w/G$, de forma independiente, el número X de lecturas en la ventana sigue una distribución binomial $\text{Bin}(N, p)$. Cuando $N \rightarrow \infty$ y $p \rightarrow 0$ con $Np = \lambda$ fijo,

$$\mathbb{P}(X = k) \rightarrow \frac{e^{-\lambda} \lambda^k}{k!}, \quad \lambda = \frac{Nw}{G}, \quad (13.4)$$

y el valor p de observar al menos k lecturas es la cola superior

$$p(k) = \mathbb{P}(X \geq k) = 1 - \sum_{i=0}^{k-1} \frac{e^{-\lambda} \lambda^i}{i!}. \quad (13.5)$$

DONDE

N	Número total de lecturas (o fragmentos) mapeadas en la muestra tratada.
G	Tamaño efectivo del genoma: número de posiciones donde una lectura puede mapearse de forma única (unos $2,7 \times 10^9$ en humano).
w	Ancho de la ventana; en MACS, $w = 2d$.
λ	Número esperado de lecturas en la ventana bajo el fondo.
k	Número de lecturas observadas en la ventana candidata.

La demostración es el límite clásico de Poisson:

$$\binom{N}{k} p^k (1-p)^{N-k} = \frac{N(N-1) \cdots (N-k+1)}{N^k} \frac{\lambda^k}{k!} \left(1 - \frac{\lambda}{N}\right)^{N-k},$$

y el primer factor tiende a 1 mientras que el último tiende a $e^{-\lambda}$. Es la misma aproximación que, en el ??, nos dio la teoría de Lander-Waterman para la cobertura.

El fondo uniforme, sin embargo, es falso. La sonicación rompe mejor la cromatina abierta; las regiones con más copias en la línea celular producen más lecturas; algunas zonas acumulan señal en cualquier experimento. Aplicar un λ global en esas

regiones llena la lista de picos de falsos positivos. La solución de MACS (*Model-based Analysis of ChIP-Seq*), propuesta por Zhang et al. (2008), es un *Poisson dinámico*: para cada ventana candidata se toma como fondo el máximo de varias estimaciones, de modo que el modelo es conservador allí donde el control indica un sesgo.

Definición 13.2. (Lambda local de MACS)

Para una ventana candidata de ancho $2d$,

$$\lambda_{\text{local}} = \max(\lambda_{\text{BG}}, \lambda_{1k}, \lambda_{5k}, \lambda_{10k}), \quad \lambda_{w'} = c_{w'} \cdot \frac{2d}{w'} \cdot \frac{N_T}{N_C}, \quad (13.6)$$

donde $\lambda_{\text{BG}} = N_T 2d / G$ es el fondo global y $c_{w'}$ es el número de lecturas del control en una ventana de ancho $w' \in \{1, 5, 10\}$ kb centrada en el candidato.

DONDE

λ_{BG}	Fondo global: las lecturas tratadas repartidas uniformemente.
$c_{w'}$	Lecturas del control en la ventana ancha w' ; se reescalan al ancho $2d$ y a la profundidad del tratamiento.
N_T, N_C	Número de lecturas del tratamiento y del control.

Tomar el *máximo* tiene una lógica de protección: si cualquiera de las escalas indica que la región es ruidosa, el umbral sube. Las versiones posteriores, MACS2 y MACS3, conservan esta idea (por omisión con ventanas de d , 1 kb y 10 kb en el control) y añaden la corrección de Benjamini-Hochberg para obtener valores q , el modo de picos anchos para marcas como H3K27me3 y el uso directo de fragmentos pareados. El artículo original estimaba además la tasa de falsos descubrimientos de forma empírica, intercambiando los papeles de tratamiento y control: los “picos” que aparecen en el control frente al tratamiento dan una idea de cuántos falsos positivos produce el procedimiento con el mismo umbral (Zhang et al., 2008).

Ejemplo 13.1. (Un pico, dos fondos)

Un experimento tiene $N_T = 2 \times 10^7$ lecturas tratadas y $N_C = 2,5 \times 10^7$ de control; el tamaño efectivo del genoma es $G = 2,7 \times 10^9$ y $d = 200$, así que la ventana mide 400 pb. El fondo global es

$$\lambda_{\text{BG}} = \frac{2 \times 10^7 \times 400}{2,7 \times 10^9} = 2,963.$$




Figura 13.3. (a) Diez kilobases simuladas: el *pileup* del tratamiento (azul) muestra un pico fuerte cerca de 5,2 kb y un enriquecimiento débil cerca de 2,3 kb. La línea naranja es el fondo local estimado del control suavizado, que nunca baja del fondo global (roja discontinua), tal como impone el máximo de la ecuación (13.6). (b) Distribución de Poisson con $\lambda_{\text{local}} = 3,2$ en escala logarítmica. Diecisiete lecturas en una ventana de 400 pb caen en la cola roja, cuya probabilidad total es $5,4 \times 10^{-8}$ (ejemplo 13.1). Observe cuán rápido decae la cola: cada lectura adicional multiplica la evidencia.

En el control hay 10 lecturas en la ventana de 1 kb, 45 en la de 5 kb y 95 en la de 10 kb. Reescalando con el factor de profundidad $N_T/N_C = 0,8$: $\lambda_{1k} = 10 \cdot 0,4 \cdot 0,8 = 3,200$, $\lambda_{5k} = 45 \cdot 0,08 \cdot 0,8 = 2,880$ y $\lambda_{10k} = 95 \cdot 0,04 \cdot 0,8 = 3,040$. Entonces $\lambda_{\text{local}} = 3,200$. Con $k = 17$ lecturas en la ventana,

$$p = P(X \geq 17 \mid \lambda = 3,2) = 5,38 \times 10^{-8}, \quad -\log_{10} p = 7,27,$$

un pico claro. Con el umbral de MACS por omisión en su versión original ($p < 10^{-5}$), bastan 14 lecturas.

Ahora considere otra región, idéntica en el tratamiento, pero en una amplificación de la línea celular: el control tiene 400 lecturas en 10 kb, así que $\lambda_{10k} = 12,8$. Con $k = 14$ lecturas, el fondo global daría $p = 2,96 \times 10^{-6}$ (un “pico”), mientras que el fondo local da $p = 0,405$: nada notable. El control ha evitado un falso positivo que ninguna profundidad de secuenciación habría corregido.

Llamada de picos con MACS3

```
# ChIP de un factor de transcripción, pares de lecturas
macs3 callpeak -t chip_rep1.bam -c input.bam \
    -f BAMPE -g hs -n ctfc_rep1 -q 0.01 --outdir picos/
# salidas: *_peaks.narrowPeak (BED6+4) y *_summits.bed
```

13.1.6 Calidad y reproducibilidad

Una lista de picos no vale nada si no se sabe cuánto de ella es señal. Tres controles se han vuelto estándar.

FRiP. La fracción de lecturas en picos (*fraction of reads in peaks*) es el cociente entre las lecturas que caen dentro de los picos llamados y el total. Mide la relación señal/ruido de todo el experimento: si 3,1 millones de 20 millones de lecturas caen en picos, FRiP = 0,155. Las guías de ENCODE consideran aceptables, para factores de transcripción, valores del 1 % o más, aunque los buenos experimentos con factores abundantes como CTCF superan con holgura esa cifra (Landt et al., 2012).

Lista negra. Algunas regiones del genoma (repeticiones satélite cerca de centrómeros y telómeros, ADN ribosómico, secuencias con copias no representadas en la referencia) producen señal alta en *cualquier* experimento de secuenciación, independientemente del tipo celular o del anticuerpo. Amemiya et al. (2019) definieron la *lista negra de ENCODE* para humano, ratón, gusano y mosca, y recomiendan eliminar sus regiones como paso de calidad esencial antes de cualquier análisis.

IDR. Dos réplicas biológicas de un mismo experimento deberían coincidir en sus picos fuertes y discrepar en los débiles, que son ruido. Li et al. (2011) formalizaron esta intuición en la *tasa de irreproducibilidad* (*irreproducible discovery rate*, IDR). Su modelo supone que cada pico pertenece a uno de dos grupos: reproducible, cuyas puntuaciones en las dos réplicas están correlacionadas, o irreproducible, cuyas puntuaciones son independientes. Las puntuaciones se transforman en rangos (para no depender de la escala de cada llamador de picos) y una mezcla de dos cópulas gaussianas se ajusta por EM, el mismo algoritmo que veremos en la sección 13.3. Para cada pico i se obtiene la probabilidad posterior de ser irreproducible, idr_i , y para una lista de los picos más fuertes S_γ ,

$$\text{IDR}(\gamma) = \frac{1}{|S_\gamma|} \sum_{i \in S_\gamma} \text{idr}_i, \quad (13.7)$$

DONDE

idr_i	Probabilidad posterior, según la mezcla, de que el pico i pertenezca al grupo irreproducible.
S_γ	Conjunto de picos seleccionados con el umbral γ (p. ej., los que tienen $\text{idr}_i \leq \gamma$).

que es el análogo exacto de la tasa de falsos descubrimientos: la fracción esperada de picos irreproducibles en la lista. El protocolo de ENCODE llama picos de forma permisiva en cada réplica y conserva los que superan el umbral de IDR elegido (típicamente 0,05) (Landt et al., 2012). En una simulación con 1500 picos reales y 2500 de ruido, la correlación de Spearman global entre réplicas es de solo 0,70, pero los 857 picos que están entre los mil primeros de *ambas* réplicas son todos reales: la estructura que el modelo aprende está en la cabeza de las listas.

⚠ Errores frecuentes en ChIP-seq

1. *Sin control o con un control poco profundo.* El control debe tener al menos tanta profundidad como el tratamiento; si no, λ_{local} se estima con mucho ruido.
2. *Duplicados de PCR.* Muchas lecturas idénticas apiladas en la misma posición inflan los conteos y violan la independencia del modelo de Poisson; se marcan y se eliminan (o se limita su número) antes de llamar picos.

13.1.7 ATAC-seq: medir la accesibilidad

ChIP-seq necesita un anticuerpo por proteína y millones de células. Una pregunta más general (¿qué regiones del genoma están *abiertas*, libres de nucleosomas y disponibles para cualquier factor?) se responde con una idea ingeniosa. La transposasa Tn5, en una versión hiperactiva cargada con adaptadores de secuenciación, corta el ADN e inserta los adaptadores en el mismo acto (“tagmentación”). En la cromatina nativa, Tn5 solo accede a los segmentos no protegidos: las regiones libres de nucleosomas y los conectores entre nucleosomas. Buenrostro et al. (2013) llamaron a la técnica ATAC-seq (*assay for transposase-accessible chromatin using sequencing*) y mostraron que un protocolo de dos pasos con 500 a 50 000 células revela a la vez la cromatina abierta, la unión de factores y la posición de nucleosomas individuales; el protocolo detallado está en Buenrostro et al. (2015). Como Tn5 corta como dímero




Figura 13.4. Principio de ATAC-seq. La transposasa Tn5 (triángulos magenta) inserta adaptadores solo donde el ADN no está protegido: en la región libre de nucleosomas (NFR) alrededor de un factor unido y en los conectores entre nucleosomas (círculos grises). Dos inserciones sucesivas definen un fragmento secuenciable; su longitud revela lo que había entre ellas: nada (fragmentos cortos de la NFR), un nucleosoma (unos 200 pb) o dos (unos 400 pb).

con un escalonamiento de 9 pb, los análisis de alta resolución desplazan las lecturas $+4/-5$ pb para situar el centro exacto de cada inserción (Buenrostro et al., 2013).

Dos inserciones de Tn5 definen un fragmento, y su longitud es un registro directo de lo que había entre ellas (figura 13.4). Por eso la distribución de tamaños de fragmento de un buen experimento de ATAC-seq tiene una forma inconfundible: una gran población por debajo de 100 pb, procedente de regiones libres de nucleosomas, y una serie de “jorobas” en múltiplos de la repetición nucleosomal. Podemos escribirla como una mezcla:

$$h(\ell) = \pi_0 h_0(\ell) + \sum_{j=1}^J \pi_j \mathcal{N}(\ell; j \ell_{\text{nuc}}, \sigma_j^2), \quad \sum_{j=0}^J \pi_j = 1, \quad (13.8)$$

DONDE

$h(\ell)$	Densidad de la longitud ℓ de los fragmentos.
h_0	Componente libre de nucleosomas (fragmentos cortos, con moda por debajo de 100 pb).
ℓ_{nuc}	Repetición nucleosomal efectiva (unos 190–200 pb: 147 del núcleo más el conector).
π_j, σ_j	Proporción y dispersión de los fragmentos que abarcan j nucleosomas.

A esta forma gruesa se superpone una oscilación fina de unos 10,5 pb, el paso de la doble hélice: Tn5 corta preferentemente el lado de la hélice expuesto, de modo que las distancias entre cortes favorecen múltiplos de una vuelta. La figura 13.5 (a) muestra

una distribución simulada con ese modelo, en la que el 38 % de los fragmentos mide menos de 100 pb y el 21 % cae en el intervalo mononucleosomal (180–247 pb).

Definición 13.3. (Enriquecimiento en TSS)

Sea $I(x)$ el número de inserciones de Tn5 acumuladas en la posición x relativa a todos los sitios de inicio de la transcripción (TSS) del genoma, orientados según la hebra del gen. El perfil normalizado es

$$E(x) = \frac{I(x)}{\frac{1}{2m} \left(\sum_{u=-2000}^{-2000+m-1} I(u) + \sum_{u=2000-m+1}^{2000} I(u) \right)}, \quad (13.9)$$

es decir, el conteo dividido por el promedio en los extremos de la ventana (m posiciones a cada lado, típicamente 100 pb). La *puntuación de enriquecimiento en TSS* es $\max_x E(x)$ cerca de $x = 0$.

DONDE

$I(x)$	Inserciones acumuladas a distancia x del TSS (en pb, con signo según la orientación del gen).
m	Ancho de los bordes usados como fondo.
$E(x)$	Enriquecimiento relativo al fondo lejano; vale ≈ 1 lejos del TSS.

Los promotores activos son las regiones abiertas más universales, así que un experimento que “ve” cromatina abierta debe mostrar un pico agudo en el TSS. Un enriquecimiento bajo (digamos, inferior a 5) indica demasiadas lecturas de fondo, típicamente por células muertas o lisis excesiva de los núcleos. El perfil simulado de la figura 13.5 (b) alcanza 8,35, con un pequeño hombro río abajo que corresponde al nucleosoma +1, bien posicionado en los genes activos.

CUT&RUN. Una alternativa moderna a ChIP-seq invierte la lógica del experimento. En lugar de fragmentar toda la cromatina y luego pescar los trozos que interesan, CUT&RUN (*cleavage under targets and release using nuclease*) lleva una nucleasa hasta la proteína de interés: un anticuerpo se une al factor en núcleos intactos y una nucleasa micrococcal acoplada a proteína A corta el ADN a su alrededor, liberando solo los fragmentos unidos. Como no hay entrecruzamiento ni fragmentación global, el fondo es mínimo: Skene y Henikoff (2017) obtuvieron perfiles precisos




Figura 13.5. Controles de calidad de ATAC-seq sobre datos simulados con la mezcla de la ecuación (13.8). (a) Distribución de tamaños de fragmento en escala logarítmica: la población libre de nucleosomas (NFR) domina, y le siguen jorobas mono-, di- y trinucleosomales separadas por unos 190 pb; la ondulación fina de 10,5 pb refleja la periodicidad helicoidal del ADN. Una biblioteca sin jorobas sugiere digestión excesiva o ADN desnudo. (b) Enriquecimiento de inserciones alrededor del TSS (ecuación (13.9)), normalizado por los extremos de la ventana (línea discontinua en 1).

con aproximadamente una décima parte de la profundidad de secuenciación de ChIP-seq.

Un pico es un exceso de lecturas sobre un fondo *local*. La geometría de hebras delata la señal verdadera, el control protege frente a sesgos del genoma y la reproducibilidad entre réplicas, no el valor p , decide qué picos se conservan.

13.2 Metilación del ADN



Post-its en un libro de recetas

Piense en un libro de recetas compartido por toda una familia. Nadie reescribe las recetas, pero cada cocinero pega notas adhesivas sobre las que no quiere que se usen: “no preparar”, “solo en Navidad”. Las notas no cambian el texto, se copian cuando alguien fotocopia el libro para un hijo, y pueden despegarse. La metilación del ADN funciona de manera parecida: un grupo metilo sobre una citosina no altera la secuencia, se hereda en cada división celular gracias a una enzima que copia el patrón de la hebra vieja a la nueva, y puede borrarse. El problema técnico es que las fotocopias normales, es decir, la PCR y la secuenciación, no copian las notas. Hay que encontrar una tinta que revele dónde estaban antes de fotocopiar.

13.2.1 Citosinas metiladas e islas CpG

En los mamíferos, la metilación del ADN consiste casi exclusivamente en añadir un grupo metilo al carbono 5 de una citosina (5mC) seguida de una guanina, el dinucleótido CpG. Como el dinucleótido complementario de CpG es también CpG, la marca es simétrica en las dos hebras, y eso permite heredarla: tras la replicación, la hebra nueva se metila frente a los CpG metilados de la hebra vieja. La metilación de un promotor se asocia en general al silenciamiento estable del gen, y participa en la impronta genómica, la inactivación del cromosoma X y el control de elementos transponibles.

La metilación deja una huella en la propia secuencia del genoma. La 5mC tiende a desaminarse espontáneamente a timina, un error que la reparación corrige peor que la desaminación de la citosina normal a uracilo. A lo largo de la evolución, los CpG metilados se han ido convirtiendo en TpG (y CpA en la otra hebra), de modo que el genoma humano tiene alrededor de una cuarta parte de los CpG que esperaríamos por su composición. La excepción son las *islas CpG*: tramos de cientos a miles de pares de bases con abundantes CpG no metilados, que Bird (1986) asoció con los extremos 5' de la mayoría de los genes de vertebrados y, en particular, de los genes de mantenimiento, cuya disponibilidad debe ser constante en el núcleo. Gardiner-Garden y Frommer (1987) dieron el criterio operativo que todavía se usa, basado en la razón entre CpG observados y esperados.

Definición 13.4. (Isla CpG (criterio de Gardiner-Garden y Frommer))

Una región de longitud $L \geq 200$ pb es una isla CpG si su contenido de GC supera el 50 % y

$$\frac{\text{CpG obs.}}{\text{CpG esp.}} = \frac{n_{CG}}{n_C n_G / L} = \frac{n_{CG} L}{n_C n_G} > 0,6. \quad (13.10)$$

DONDE

n_{CG}	Número de dinucleótidos CpG en la región (en una hebra).
n_C, n_G	Número de citosinas y guaninas.
L	Longitud de la región; $n_C n_G / L$ es el número de CpG esperado si C y G se sucedieran al azar.

Ejemplo 13.2. (Dos regiones de 100 pb)

Generamos dos secuencias sintéticas de 100 pb que imitan la evolución de la desaminación: una rica en GC en la que se conserva el 90 % de los CpG (“isla”) y otra con GC moderado en la que solo se conserva el 22 % (“mar”). En la primera hay $n_C = 37$, $n_G = 32$ y $n_{CG} = 12$: GC = 69 % y

$$\frac{\text{obs.}}{\text{esp.}} = \frac{12 \times 100}{37 \times 32} = 1,01 > 0,6.$$

En la segunda, $n_C = 22$, $n_G = 17$ y un único CpG: GC = 39 % y obs./esp. = $100/(22 \times 17) = 0,27$, el valor típico del “mar” genómico. (Para aplicar formalmente el criterio habría que usar ventanas de al menos 200 pb.)

13.2.2 La química del bisulfito

Ni la PCR ni los secuenciadores de síntesis distinguen 5mC de C: la polimerasa pone una G frente a ambas y el grupo metilo se pierde en la primera copia. La solución clásica es química. El bisulfito de sodio desamina la citosina a uracilo en condiciones en las que la 5-metilcitosina, protegida por el metilo, apenas reacciona. Frommer et al. (1992) convirtieron esta reacción en un método de secuenciación genómica que identifica positivamente cada 5mC: tras el tratamiento, se amplifica por PCR y en el producto todos los uracilos (y timinas) aparecen como T, mientras que solo las 5mC siguen leyéndose como C (figura 13.6).




Figura 13.6. Química de la conversión por bisulfito en una hebra de 14 bases con dos CpG metilados (C con borde oscuro y punto naranja), un CpG no metilado (posición 5) y dos citosinas fuera de contexto CpG. El bisulfito desamina las citosinas no metiladas a uracilo (magenta); la PCR copia el uracilo como timina. Al comparar la lectura con la referencia, una C que sigue siendo C estaba metilada; una C que aparece como T no lo estaba. La hebra convertida ya no es complementaria de la original, y por eso cada hebra del genoma produce lecturas distintas.

La consecuencia para el análisis es doble. Primero, la medida es *digital* en cada molécula: cada lectura dice “C” o “T” en cada citosina de la referencia, y el nivel de metilación de un sitio es la fracción de lecturas que dicen “C”. Segundo, el alineamiento se complica, porque una lectura convertida difiere de la referencia en casi todas sus citosinas. Si la conversión fuera incompleta, algunas C no metiladas se leerían como metiladas; por eso se estima la tasa de no conversión con ADN control sin metilar añadido a la muestra, o con citosinas fuera de contexto CpG en tejidos donde apenas se metilan.

13.2.3 Secuenciación con bisulfito del genoma completo y alineamiento

La secuenciación con bisulfito del genoma completo (WGBS, *whole-genome bisulfite sequencing*) aplica la conversión a una biblioteca de todo el genoma. Lister et al. (2009) publicaron así los primeros metilomas humanos con resolución de una base, de células madre embrionarias y fibroblastos fetales, y descubrieron que casi una cuarta parte de la metilación de las células madre embrionarias estaba fuera del contexto CG, una forma que desaparecía al diferenciarse.

El problema del alineamiento. Un alineador convencional penalizaría cada T de la lectura frente a una C de la referencia. Pero no basta con permitir esos desajustes sin coste: tras la conversión, la lectura está escrita casi en un alfabeto de tres letras, y su complejidad baja tanto que muchas lecturas mapearían en varios lugares.




Figura 13.7. Estrategia de alineamiento de Bismark (Krueger & Andrews, 2011). La lectura y el genoma se convierten *in silico* al alfabeto reducido, de modo que las diferencias debidas al bisulfito desaparecen y solo quedan los verdaderos desajustes. Tras encontrar la posición única, la metilación se llama volviendo a la lectura original (flecha discontinua): la C del CpG de la lectura de ejemplo indica una citosina metilada; las T frente a C de la referencia, citosinas no metiladas.

La solución de Bismark (Krueger & Andrews, 2011) es convertir *todo* de forma computacional antes de alinear (figura 13.7): en las lecturas se reemplazan todas las C por T, y el genoma se prepara en dos versiones, una con todas las C convertidas en T (para la hebra superior) y otra con todas las G convertidas en A (para la inferior). Cada lectura se alinea con un alineador estándar contra las versiones convertidas en todas las combinaciones posibles de hebra; se conserva solo el alineamiento único con menos desajustes y, una vez ubicado, se compara la lectura *original* con la referencia *original* para llamar la metilación de cada citosina, distinguiendo los contextos CpG, CHG y CHH (con H = A, C o T).

Flujo básico de WGBS con Bismark

```

bismark_genome_preparation genoma/          # versiones C->T y G->A
bismark --genome genoma/ -1 m1_R1.fq.gz -2 m1_R2.fq.gz
deduplicate_bismark --bam m1_R1_bismark_bt2_pe.bam
bismark_methylation_extractor --bedGraph --cytosine_report \
  --genome_folder genoma/ m1_R1_bismark_bt2_pe.deduplicated.bam
# salida: por cada CpG, lecturas metiladas y no metiladas

```

13.2.4 Cuantificar: valores β y M

Para un CpG cubierto por n lecturas, de las cuales c dicen “C”, el modelo natural es binomial: $c \sim \text{Bin}(n, \beta)$, donde β es la fracción de moléculas metiladas en la muestra. El estimador de máxima verosimilitud es $\hat{\beta} = c/n$, con error estándar $\sqrt{\hat{\beta}(1 - \hat{\beta})/n}$.

Las micromatrices de Illumina (Infinium 450K y EPIC), aún muy usadas en estudios poblacionales, miden lo mismo de otra forma: para cada CpG hay dos intensidades de fluorescencia, M_s para el alelo metilado y U_s para el no metilado (tras la conversión, la sonda distingue C de T). Du et al. (2010) compararon las dos métricas en uso.

Definición 13.5. (Valores β y M)

$$\beta = \frac{\max(M_s, 0)}{\max(M_s, 0) + \max(U_s, 0) + \alpha}, \quad M = \log_2 \frac{\max(M_s, 0) + \alpha'}{\max(U_s, 0) + \alpha'}. \quad (13.11)$$

Ignorando las constantes, $M = \log_2 \frac{\beta}{1 - \beta}$: el valor M es la transformación *logit* (en base 2) del valor β .

DONDE

M_s, U_s	Intensidades de las sondas metilada y no metilada del CpG s (en WGBS, los conteos c y $n - c$).
α	Constante que estabiliza β cuando ambas intensidades son bajas (Illumina usa 100).
α'	Pequeña constante que evita el logaritmo de cero (p. ej., 1).
$\beta \in [0, 1]$	Fracción de metilación; interpretable como porcentaje de moléculas metiladas.
$M \in \mathbb{R}$	Valor M ; $M = 0$ corresponde a $\beta = 0,5$.

¿Por qué dos métricas? El valor β tiene una interpretación biológica directa, pero su varianza depende de su media: cerca de 0 y de 1 está comprimido por los límites del intervalo. El método delta muestra que la transformación *logit* compensa exactamente esa compresión. Si $\text{Var}(\hat{\beta}) \approx \beta(1 - \beta)/n$ (binomial), entonces

$$\text{Var}(\hat{M}) \approx \left(\frac{dM}{d\beta} \right)^2 \text{Var}(\hat{\beta}) = \frac{1}{(\beta(1 - \beta) \ln 2)^2} \cdot \frac{\beta(1 - \beta)}{n} = \frac{1}{n \beta(1 - \beta) (\ln 2)^2}, \quad (13.12)$$




Figura 13.8. Distribución de 400 000 CpG simulados con intensidades de tipo Infinium. (a) La distribución de β es fuertemente bimodal: el 32,5 % de los sitios tiene $\beta < 0,2$ (sobre todo CpG de islas, no metilados) y el 43,1 % tiene $\beta > 0,8$ (el mar genómico, metilado). (b) Los mismos datos en escala M : los dos modos se separan y se ensanchan. (c) La transformación logit estira los extremos del intervalo $[0, 1]$, compensando la compresión de la varianza de β cerca de 0 y de 1 (ecuación (13.12)).

DONDE

$dM/d\beta$	Derivada de la transformación logit en base 2, $1/(\beta(1-\beta) \ln 2)$.
n	Número de moléculas (lecturas) que sustentan la medida.

y los contrastes en la escala M ya no tratan igual una diferencia de 0,05 en torno a $\beta = 0,5$ que en torno a $\beta = 0,97$, donde la segunda es mucho más significativa biológica y estadísticamente. Du et al. (2010) concluyeron que β es preferible para informar resultados y M para el análisis diferencial en micromatrices, cuya varianza técnica es más homogénea en esa escala. En WGBS, donde los datos son conteos, lo más limpio es modelar directamente la binomial, como veremos enseguida.

13.2.5 Metilación diferencial: el modelo beta-binomial

Al comparar dos grupos (tumor y tejido normal, tratados y controles) buscamos CpG individuales (*differentially methylated loci*, DML) o regiones (DMR) cuyo nivel de metilación difiera. El modelo binomial captura el muestreo de lecturas, pero no la variación *biológica* entre réplicas: dos individuos sanos no tienen exactamente la misma β en un CpG. Ignorar esa variabilidad subestima la varianza y produce

avalanchas de falsos positivos, exactamente el mismo fenómeno de sobredispersión que en RNA-seq obliga a pasar de la Poisson a la binomial negativa (??).

Teorema 13.3. (Varianza beta-binomial)

Si en la réplica r la fracción de metilación es $p_r \sim \text{Beta}(a, b)$ con media $\mu = a/(a + b)$ y dispersión $\phi = 1/(a + b + 1)$, y $c_r \mid p_r \sim \text{Bin}(n_r, p_r)$, entonces

$$\mathbb{E}[c_r] = n_r \mu, \quad \text{Var}(c_r) = n_r \mu(1 - \mu) [1 + (n_r - 1) \phi]. \quad (13.13)$$

DONDE

c_r, n_r	Lecturas metiladas y cobertura total del CpG en la réplica r .
p_r	Fracción de metilación verdadera de la réplica (varía entre individuos).
μ	Media de metilación del grupo en ese CpG.
$\phi \in [0, 1)$	Dispersión: correlación entre dos lecturas de la misma réplica; $\phi = 0$ recupera la binomial.

La demostración usa la ley de la varianza total: $\text{Var}(c) = \mathbb{E}[\text{Var}(c \mid p)] + \text{Var}(\mathbb{E}[c \mid p]) = n\mathbb{E}[p(1 - p)] + n^2 \text{Var}(p)$. Con $\mathbb{E}[p(1 - p)] = \mu(1 - \mu) - \text{Var}(p)$ y $\text{Var}(p) = \mu(1 - \mu)\phi$ para la beta, se obtiene $n\mu(1 - \mu)(1 - \phi) + n^2\mu(1 - \mu)\phi$, que es la ecuación (13.13). El factor $1 + (n - 1)\phi$ tiene una lectura importante: *augmentar la cobertura no elimina la variación biológica*. Con $n = 20$ y $\mu = 0,85$, la desviación estándar de c es 1,60 si $\phi = 0$, pero 2,23 con $\phi = 0,05$ y 2,72 con $\phi = 0,1$.

El paquete DSS de Feng et al. (2014) usa este modelo con una idea adicional: como con pocas réplicas la dispersión de cada CpG se estima muy mal, le asigna una distribución a priori lognormal común a todos los CpG, de modo que cada estimación se “encoge” hacia el valor típico del genoma (compartir información entre sitios). Con la dispersión estimada, contrasta la diferencia de medias con una prueba de Wald:

$$z = \frac{\hat{\mu}_A - \hat{\mu}_B}{\sqrt{\widehat{\text{Var}}(\hat{\mu}_A) + \widehat{\text{Var}}(\hat{\mu}_B)}}, \quad \widehat{\text{Var}}(\hat{\mu}_g) \approx \frac{1}{R_g^2} \sum_{r=1}^{R_g} \frac{\hat{\mu}_g(1 - \hat{\mu}_g)[1 + (n_r - 1)\hat{\phi}]}{n_r}, \quad (13.14)$$

DONDE

$\hat{\mu}_g$	Metilación estimada del grupo g : $\sum_r c_r / \sum_r n_r$.
R_g	Número de réplicas del grupo g .
$\hat{\phi}$	Dispersión estimada (encogida) del CpG.
z	Estadístico de Wald; bajo H_0 sigue aproximadamente una normal estándar.

Ejemplo 13.3. (Un CpG, tres réplicas por grupo)

Primero, una sola muestra: 17 de 20 lecturas dicen “C”. Entonces $\hat{\beta} = 0,850$, con error estándar binomial 0,080. El intervalo de Wald al 95 %, (0,694; 1,006), se sale de [0, 1]: con proporciones cercanas a los extremos conviene un intervalo bayesiano de Jeffreys (a priori Beta($\frac{1}{2}$, $\frac{1}{2}$)), que da (0,651; 0,956). El valor M , con $\alpha' = 1$, es $\log_2(18/4) = 2,17$.

Ahora, el grupo A tiene conteos 17/20, 22/25 y 14/18, y el grupo B, 6/21, 9/24 y 5/19. Las medias son $\hat{\mu}_A = 53/63 = 0,841$ y $\hat{\mu}_B = 20/64 = 0,312$. Con $\hat{\phi} = 0,05$, la ecuación (13.14) da $\widehat{\text{Var}}(\hat{\mu}_A) = 0,00428$, $\widehat{\text{Var}}(\hat{\mu}_B) = 0,00680$ y

$$z = \frac{0,841 - 0,312}{\sqrt{0,00428 + 0,00680}} = 5,02, \quad p = 5,1 \times 10^{-7}.$$

Si ignoráramos la dispersión ($\phi = 0$) obtendríamos $z = 7,10$ y $p = 1,3 \times 10^{-12}$: cinco órdenes de magnitud de “evidencia” que no existen. Con $\phi = 0,1$, $z = 4,10$; con $\phi = 0,2$, $z = 3,18$ y $p = 0,0015$. La conclusión depende críticamente de cuánto varían los individuos, y por eso las réplicas biológicas son irrenunciables.

De sitios a regiones. Los CpG vecinos están fuertemente correlacionados: la metilación cambia por bloques de cientos de pares de bases, no sitio a sitio. Los métodos de DMR aprovechan esa estructura suavizando los niveles de metilación a lo largo del genoma (lo que además “presta” cobertura de los vecinos a los CpG poco cubiertos) y agrupando CpG significativos contiguos en regiones, con requisitos mínimos de longitud, número de CpG y diferencia media. La figura 13.9 muestra una simulación de 55 CpG en 3 kb: la prueba de Wald con $\phi = 0,05$ declara significativos ($p < 0,01$) 15 CpG, de los que 14 están dentro de la DMR verdadera (1100 pb a 1900 pb); el tramo contiguo más largo de CpG significativos, de 1159 a 1835 pb, recupera la región casi exactamente.




Figura 13.9. Región diferencialmente metilada simulada: 55 CpG en 3 kb, tres réplicas por grupo, cobertura media de 14 lecturas y datos beta-binomiales con $\phi = 0,05$. **Arriba:** niveles por réplica (puntos) y curvas suavizadas con un núcleo gaussiano de 150 pb. El grupo B pierde la metilación en un bloque central, como ocurre en la hipometilación de un potenciador activado. **Abajo:** significancia de la prueba de Wald beta-binomial por CpG (ecuación (13.14)). La banda amarilla es la DMR llamada como el tramo contiguo más largo de CpG con $p < 0,01$. Los puntos individuales son muy ruidosos; la región, en cambio, es inequívoca.

13.2.6 Relojes epigenéticos y metilación sin bisulfito

La metilación cambia con la edad de manera tan regular que puede usarse como reloj. Horvath (2013) entrenó un predictor multitejido con unas 8000 muestras de micromatrices de 82 conjuntos de datos y 51 tejidos y tipos celulares sanos: una regresión penalizada (red elástica) seleccionó 353 CpG cuya combinación lineal, tras una transformación de la edad logarítmica en la infancia y lineal en la adultez, estima la “edad epigenética”. Esta edad es cercana a cero en células madre embrionarias e inducidas, aumenta con el número de pases en cultivo y aparece acelerada en muchos tipos de cáncer. La diferencia entre la edad epigenética y la cronológica, la *aceleración*, se ha convertido en un biomarcador muy estudiado.

Nanoporos. La secuenciación por nanoporos (??) lee la molécula nativa, sin amplificar, y la corriente iónica depende de las bases que ocupan el poro, incluidas las modificadas. Simpson et al. (2017) entrenaron un modelo oculto de Márkov con ADN metilado sintéticamente para distinguir 5mC de citosina en la señal eléctrica y obtuvieron el metiloma humano sin ningún paso especial de preparación. Sin bisulfito no hay degradación del ADN ni pérdida de complejidad, las lecturas largas permiten “fasear” la metilación con los alelos, y la misma corrida entrega secuencia y epigenoma.

⚠ Trampas de la metilación

1. *C→T que no es bisulfito.* Un SNP C/T en la muestra es indistinguible de una C no metilada en la hebra correspondiente; hay que filtrar posiciones polimórficas o mirar la hebra opuesta (donde el SNP aparece como G/A y el bisulfito no actúa).
2. *Composición celular.* Una diferencia de metilación entre tejidos enfermos y sanos puede reflejar solo una proporción distinta de tipos celulares. Deconvolucionar o ajustar por composición es obligatorio en muestras de sangre y tumores.

El bisulfito convierte una marca química invisible en una diferencia de secuencia (C frente a T). La metilación de un sitio es una proporción de lecturas, y su comparación entre grupos exige un modelo que separe el ruido de muestreo (binomial) de la variación biológica (dispersión beta).

13.3 Descubrimiento de motivos regulatorios

Suponga que intercepta treinta cartas escritas en un alfabeto de cuatro letras, casi todas con texto sin sentido. Le han dicho que en cada una hay escondida, en algún lugar, una misma contraseña de ocho letras, pero copiada con errores. Si supiera dónde está en cada carta, bastaría alinear los fragmentos y contar letras. Si conociera la contraseña, bastaría buscarla en cada carta. No sabe ninguna de las dos cosas. La salida es circular pero funciona: adivine una contraseña aproximada, busque en cada carta el fragmento que más se le parece, reconstruya la contraseña a partir de esos fragmentos, y repita. Cada vuelta mejora un poco las dos conjeturas a la vez, hasta que dejan de cambiar.

Un pico de ChIP-seq indica *dónde* se une un factor, pero con una resolución de decenas o cientos de pares de bases. La especificidad de la unión reside en un segmento corto de 6 a 20 pb, el *motivo*, que el ?? representó con una matriz de peso posicional (PWM) y un *sequence logo*. Allí la matriz se construía a partir de sitios conocidos. Aquí el problema es el inverso: dados cientos o miles de secuencias que *probablemente* contienen el motivo en alguna posición desconocida, aprender simultáneamente la matriz y las posiciones. Es un ejemplo de manual de problema con *datos incompletos*.

13.3.1 El modelo generativo

Sean $X_1, \dots, X_N$ secuencias de longitud L y W el ancho del motivo; cada secuencia tiene $m = L - W + 1$ posiciones de inicio posibles. El modelo más sencillo, llamado OOPS (*one occurrence per sequence*), supone que cada secuencia contiene exactamente un sitio, cuyas W bases se generan con la matriz θ (una distribución sobre $\{A, C, G, T\}$ por columna), mientras que el resto de las bases proviene de un fondo p_0 . Introducimos variables *ocultas* $Z_{ij} \in \{0, 1\}$ que valen 1 si el sitio de la secuencia i empieza en la posición j .

Definición 13.6. (Verosimilitud del modelo OOPS)

Con un inicio uniforme ($\mathbb{P}(Z_{ij} = 1) = 1/m$), la razón de verosimilitudes de la secuencia X_i frente al modelo de fondo puro es

$$\frac{\mathbb{P}(X_i | \theta)}{\mathbb{P}(X_i | p_0)} = \frac{1}{m} \sum_{j=1}^m r_{ij}(\theta), \quad r_{ij}(\theta) = \prod_{k=1}^W \frac{\theta_{k, x_{i,j+k-1}}}{p_0(x_{i,j+k-1})}, \quad (13.15)$$

y la log-verosimilitud del conjunto, en bits, es $\text{LLR}(\theta) = \sum_i \log_2 \left(\frac{1}{m} \sum_j r_{ij}(\theta) \right)$.

DONDE

$x_{i,j}$	Base en la posición j de la secuencia i .
$\theta_{k,b}$	Probabilidad de la base b en la columna k del motivo.
$p_0(b)$	Frecuencia de fondo de la base b .
r_{ij}	Razón de verosimilitudes de que el sitio esté en j frente a que sea fondo; $\log_2 r_{ij}$ es la puntuación PWM del ??.
m	Número de posiciones de inicio posibles, $L - W + 1$.

Las bases fuera del sitio se cancelan en el cociente, así que solo quedan las W columnas del candidato. Si conociéramos las Z_{ij} , estimar θ sería contar; si conociéramos θ , localizar los sitios sería escanear con la PWM. El algoritmo EM convierte esta circularidad en un procedimiento con garantías.

13.3.2 El algoritmo EM y MEME

Dempster et al. (1977) formularon el algoritmo de esperanza-maximización (EM) en general para problemas con datos faltantes. Aplicado a motivos alterna dos pasos:

Teorema 13.4. (EM para el modelo OOPS)

Dada una estimación $\theta^{(t)}$:

$$\text{Paso E: } Z_{ij}^{(t)} = \mathbb{P}(Z_{ij} = 1 \mid X_i, \theta^{(t)}) = \frac{r_{ij}(\theta^{(t)})}{\sum_{j'=1}^m r_{ij'}(\theta^{(t)})}, \quad (13.16)$$

$$\text{Paso M: } \theta_{k,b}^{(t+1)} = \frac{\sum_i \sum_j Z_{ij}^{(t)} \mathbb{1}[x_{i,j+k-1} = b] + \beta_b}{\sum_{b'} (\sum_i \sum_j Z_{ij}^{(t)} \mathbb{1}[x_{i,j+k-1} = b'] + \beta_{b'})}. \quad (13.17)$$

Con $\beta_b = 0$, cada iteración no disminuye la verosimilitud: $\text{LLR}(\theta^{(t+1)}) \geq \text{LLR}(\theta^{(t)})$.

DONDE

$Z_{ij}^{(t)}$	Probabilidad posterior de que el sitio de la secuencia i empiece en j ; es un “conteo fraccionario”.
β_b	Seudoconteos (a priori de Dirichlet) que evitan probabilidades nulas.
$\mathbb{1}[\cdot]$	Función indicadora.

El paso E reparte cada secuencia entre sus posiciones posibles en proporción a cuánto se parecen al motivo actual: en vez de decidir dónde está el sitio, reparte “votos”. El paso M construye una nueva PWM con esos votos fraccionarios. La garantía de monotonía viene de la desigualdad de Jensen: para cualquier distribución q sobre las variables ocultas, $\log \mathbb{P}(X \mid \theta) \geq \sum_Z q(Z) \log \frac{\mathbb{P}(X, Z \mid \theta)}{q(Z)}$, con igualdad cuando q es la posterior. El paso E hace la cota exacta en $\theta^{(t)}$; el paso M la maximiza en θ ; por tanto la verosimilitud en $\theta^{(t+1)}$ es al menos la cota, que es al menos la verosimilitud en $\theta^{(t)}$. Lo que EM *no* garantiza es el máximo global.

Ejemplo 13.4. (Un paso E)

En una colección simulada de 30 secuencias de 80 pb con un motivo de tipo AP-1 implantado (consenso **ATGASTCA**, $W = 8$; hay $m = 73$ posiciones por secuencia), la secuencia 18 contiene el sitio **ATGACTCA**, idéntico al consenso. Con la matriz verdadera y fondo uniforme, su puntuación es

$$\log_2 r = 1,26 + 1,77 + 1,77 + 1,82 + 0,91 + 1,77 + 1,77 + 1,82 \approx 12,87 \text{ bits,}$$

es decir, $r \approx 7500$: el sitio es unas siete mil quinientas veces más probable bajo el motivo que bajo el fondo. Al normalizar sobre las 73 posiciones, el paso E le asigna $Z = 0,9976$ y reparte el 0,24 % restante entre las otras 72. Pero no todos los sitios son tan claros: la mediana de las puntuaciones de los 30 sitios reales es de 8,65 bits, y en las secuencias con sitios degenerados el paso E reparte el voto entre varias posiciones. Cambiar una sola base (ATGACTTA) baja la puntuación a 8,78 bits.

```
em_oops.py

import numpy as np

def em_oops(seqs, theta, iters=30, beta=0.1):
    """seqs: matriz N x L de enteros 0-3; theta: W x 4 inicial."""
    N, L = seqs.shape
    W = theta.shape[0]
    win = np.stack([seqs[:, j:j + W] for j in range(L - W + 1)], 1)
    for _ in range(iters):
        lr = np.log2(theta[np.arange(W), win]).sum(-1) + 2 * W
        Z = np.exp2(lr - lr.max(1, keepdims=True))      # paso E
        Z /= Z.sum(1, keepdims=True)
        cnt = np.stack([(Z[..., None] * (win == b)).sum((0, 1))
                        for b in range(4)], 1)          # paso M
        theta = (cnt + beta) / (cnt + beta).sum(1, keepdims=True)
    return theta, Z
```

MEME. El programa MEME, presentado por Bailey y Elkan en 1994 y hoy núcleo de la MEME Suite (Bailey et al., 2009), es la implementación de referencia de esta idea. Añade tres ingredientes decisivos. Primero, modelos más realistas que OOPS: ZOOPS (*zero or one occurrence per sequence*), que admite secuencias sin sitio, y TCM (*two-component mixture*), que admite cualquier número. Segundo, una estrategia de *inicialización*: en lugar de partir de una matriz aleatoria, prueba como semillas subcadenas reales de los datos, corre una iteración corta desde cada una y lanza EM completo solo desde las más prometedoras. Tercero, un criterio estadístico (el valor E del motivo) para decidir cuántos motivos reportar y de qué ancho.

La figura 13.10 (a) muestra por qué la inicialización importa. Seis corridas de EM sobre el mismo conjunto, cinco con semillas aleatorias y una con una subcadena de la secuencia, terminan en tres destinos. Dos alcanzan la verosimilitud máxima encontrada, LLR = 96,4 bits, con el consenso ATGAGTCA (la S del motivo admite C o




Figura 13.10. Descubrimiento de un motivo de 8 pb implantado en 30 secuencias de 80 pb. (a) Log-verosimilitud (ecuación (13.15)) a lo largo de las iteraciones de EM desde seis puntos de partida: cinco semillas aleatorias y una subcadena de los datos (naranja discontinua), como hace MEME. Todas las curvas son crecientes, como garantiza el teorema 13.4, pero terminan en óptimos distintos; la mejor corrida con semilla aleatoria (azul) muestra la típica curva en S. (b) Cuatro cadenas del muestreador de Gibbs: la trayectoria es ruidosa porque cada paso es aleatorio. Una cadena (azul) encuentra el motivo en seis barridos; dos quedan desfasadas dos posiciones y una no encuentra nada. La línea roja es la verosimilitud de la matriz verdadera.

G). Otras quedan atrapadas en versiones *desfasadas* del motivo (**TGAGTCAT**, **CATGACTC**), que capturan solo siete de las ocho columnas, o en un óptimo local pobre (LLR = 56,5). La curva de la corrida ganadora tiene forma de S: durante cinco iteraciones apenas mejora, hasta que un puñado de sitios reales “tira” de la matriz y el resto la sigue en cascada. En esa corrida, 26 de los 30 sitios implantados se recuperan en la posición exacta, y la matriz final tiene 8,75 bits de información, *más* que la verdadera (8,11): con solo 30 sitios, la máxima verosimilitud sobreajusta y hace el motivo más nítido de lo que es. Por la misma razón, la LLR de la solución (96,4 bits) supera a la de la matriz verdadera (76,1).

13.3.3 Muestreo de Gibbs

Lawrence et al. (1993) abordaron el mismo problema con una estrategia estocástica, el *muestreador de sitios* de Gibbs. En lugar de probabilidades fraccionarias, mantiene una asignación concreta $a = (a_1, \dots, a_N)$ de la posición del sitio en cada secuencia y la actualiza de una en una:




Figura 13.11. Un motivo emerge del ruido. **Arriba, izquierda:** logo de la matriz usada para implantar los sitios (8,11 bits en total; la columna 5 es una S = C/G). Los otros cinco logos siguen la corrida ganadora de EM desde una semilla aleatoria (TTCCCTTA): la semilla apenas tiene 1,66 bits; en la iteración 6 empiezan a asomar la G, la A y la T centrales (3,19 bits); en la iteración 8 el motivo ya es reconocible (6,39 bits), y al converger (8,75 bits) coincide con el implantado. **Abajo, derecha:** la mejor cadena de Gibbs tras 60 barridos llega al mismo motivo por un camino estocástico. Alturas en bits según la ecuación del logo del ??.

1. Elija una secuencia z y retire su sitio del alineamiento.
2. Construya la matriz con los $N - 1$ sitios restantes y pseudoconteos:

$$q_{k,b} = \frac{\sum_{i \neq z} \mathbb{1}[x_{i,a_i+k-1} = b] + \beta_b}{N - 1 + \sum_{b'} \beta_{b'}}. \quad (13.18)$$

3. Muestree una nueva posición para z de la distribución condicional

$$\mathbb{P}(a_z = j \mid a_{-z}, X) \propto \prod_{k=1}^W \frac{q_{k, x_{z,j+k-1}}}{p_0(x_{z,j+k-1})}, \quad j = 1, \dots, m. \quad (13.19)$$

4. Repita para todas las secuencias (un *barrido*) hasta que la verosimilitud se estabilice.

DONDE

a_i	Posición asignada al sitio de la secuencia i .
a_{-z}	Posiciones de todas las secuencias excepto z .
$q_{k,b}$	Matriz estimada sin la secuencia z .

La diferencia con EM es de fondo. EM es determinista y sube siempre por la pendiente más cercana; Gibbs es una cadena de Márkov cuya distribución estacionaria es la posterior de las posiciones, así que puede *bajar* momentáneamente y saltar a otra colina. En la práctica, las dos estrategias tienen los mismos enemigos: los óptimos locales y, sobre todo, los *desfases* (*phase shifts*), en los que el alineamiento captura el motivo corrido una o dos posiciones. Los dos desfases de la figura 13.10 (b) (ACATGAGT y CCATGAGT) contienen seis columnas buenas de ocho y son muy estables, porque mover un único sitio no mejora nada; hace falta desplazar todos a la vez. Lawrence et al. (1993) propusieron por ello movimientos que desplazan todo el alineamiento, y la práctica habitual es lanzar muchas cadenas y quedarse con la mejor. En nuestra simulación, la cadena ganadora alcanzó el 95 % de su verosimilitud final en el sexto barrido y colocó 22 de los 30 sitios en la posición exacta.

13.3.4 De motivos nuevos a factores conocidos: bases de datos y enriquecimiento

Un motivo descubierto *de novo* es solo una matriz. Para ponerle nombre se compara con bases de datos de perfiles de unión. JASPAR, en su novena versión, es la colección abierta de referencia de perfiles de factores de transcripción curados y no redundantes (Castro-Mondragon et al., 2022); la comparación entre matrices (por ejemplo, con la herramienta Tomtom de la MEME Suite, que puntúa la similitud columna a columna considerando desplazamientos y la hebra complementaria) devuelve los factores conocidos más parecidos con un valor de significancia (Bailey et al., 2009).

Enriquecimiento diferencial. Una pregunta distinta, y a menudo más útil, es cuál de los miles de motivos conocidos aparece *más* en los picos que en secuencias de fondo comparables. HOMER (Heinz et al., 2010) popularizó este enfoque con un fondo de secuencias genómicas aleatorias emparejadas por contenido de GC con los picos, lo que evita que cualquier motivo rico en GC parezca enriquecido solo porque los promotores lo son. Con ese enfoque, Heinz et al. (2010) mostraron que el factor PU.1 colabora con pequeños conjuntos de factores determinantes de linaje para establecer los potenciadores propios de macrófagos y linfocitos B. La significancia se calcula con la distribución hipergeométrica:

$$p = \mathbb{P}(K \geq k_t) = \sum_{k \geq k_t} \frac{\binom{k_t + k_b}{k} \binom{n_t + n_b - k_t - k_b}{n_t - k}}{\binom{n_t + n_b}{n_t}}, \quad (13.20)$$

DONDE

n_t, k_t	Número de secuencias objetivo (picos) y cuántas contienen el motivo.
n_b, k_b	Número de secuencias de fondo y cuántas lo contienen.
K	Número de secuencias con motivo que caerían en el conjunto objetivo si la asignación fuera al azar.

es decir, la probabilidad de que, repartiendo al azar las $k_t + k_b$ secuencias con motivo entre objetivo y fondo, al menos k_t caigan en el objetivo.

Ejemplo 13.5. (Un motivo enriquecido)

De 2000 picos, 640 (32 %) contienen el motivo; de 20 000 secuencias de fondo emparejadas por GC, lo contienen 1200 (6 %). El enriquecimiento es $0,32/0,06 = 5,33$ veces, y la ecuación (13.20) da $p = 6,8 \times 10^{-234}$ ($\ln p = -536,9$, la escala que HOMER reporta). La aproximación binomial, que trata el fondo como una proporción conocida sin error, da un valor aún menor (2×10^{-276}). Valores tan extremos son habituales y no deben leerse literalmente: con miles de secuencias, cualquier sesgo sistemático de composición da p astronómicos. Lo que importa es el *orden* de los motivos y el tamaño del enriquecimiento.

13.3.5 Centralidad: ¿unión directa o indirecta?

Un motivo enriquecido en los picos no es necesariamente el del factor inmunoprecipitado: puede ser el de un cofactor que se une cerca, o reflejar un sesgo de las regiones abiertas. Bailey y Machanick (2012) observaron que, si el factor se une *directamente* al ADN, sus sitios deben concentrarse en el centro de los picos (la posición del *summit*), mientras que los de cofactores se distribuyen más anchos y los del fondo, uniformemente. Su herramienta CentriMo busca la ventana central donde el enriquecimiento es máximo y lo contrasta con una prueba binomial: si una ventana de ancho w_c ocupa una fracción $f = w_c/(L - W + 1)$ de las posiciones posibles, el número de mejores sitios que caen dentro sigue, bajo la hipótesis nula, una $\text{Bin}(n, f)$. Así mostraron, por ejemplo, que en un conjunto de datos de Smad1 no había evidencia de unión directa del factor inmunoprecipitado.

Análisis de motivos a partir de picos

100 pb alrededor de la cumbre de cada pico




Figura 13.12. Análisis de centralidad al estilo de CentriMo sobre 3000 picos simulados de 500 pb. Los mejores sitios del motivo del factor inmunoprecipitado (azul) se concentran en los 100 pb centrales (banda amarilla), donde cae el 97,6 % de ellos frente al 21 % esperado; la prueba binomial da un valor p numéricamente nulo. El motivo de un cofactor (naranja) está enriquecido, pero de forma mucho más ancha ($p = 2,9 \times 10^{-35}$), y un motivo sin relación se distribuye de forma plana ($p = 0,39$). La centralidad distingue unión directa de indirecta, algo que el simple enriquecimiento no puede hacer.

```
awk -v OFS='\t' '{s=$2+$10-50; print $1,s,s+100}' \
ctcf_idr.narrowPeak > cumbres.bed
bedtools getfasta -fi hg38.fa -bed cumbres.bed -fo cumbres.fa
# MEME Suite: de novo + enriquecimiento + centralidad
meme-chip -oc memechip -meme-nmotifs 5 \
-db JASPAR2022_CORE_vertbrates.meme cumbres.fa
# HOMER: fondo emparejado por GC
findMotifsGenome.pl cumbres.bed hg38 homer_out -size given
```

⚠ Motivos que engañan

1. *Baja complejidad y repeticiones.* Tramos como CACACACA o poli-A se “descubren” con enorme significancia; enmascare repeticiones y use modelos de fondo de orden superior.
2. *Sesgo de GC.* Los promotores son ricos en GC; sin un fondo emparejado, cualquier motivo rico en GC parecerá enriquecido.

3. *Presencia no es ocupación.* Un genoma humano contiene cientos de miles de coincidencias de casi cualquier PWM; la inmensa mayoría no está ocupada, porque la accesibilidad de la cromatina (sección 13.1) decide.

Descubrir motivos es estimar una PWM con datos incompletos: EM reparte votos fraccionarios y sube por la verosimilitud; Gibbs muestrea posiciones y puede escapar de óptimos locales. Ninguno garantiza el óptimo global: múltiples arranques, fondos emparejados y el criterio de centralidad convierten una matriz en una hipótesis biológica.

☰ En resumen

- En ChIP-seq, las lecturas de las hebras + y – flanquean el sitio a una distancia igual al tamaño de fragmento, que se estima por correlación cruzada; NSC y RSC comparan el pico de fragmento con el pico fantasma de mapabilidad.
- MACS llama picos con una prueba de Poisson cuya media es el máximo entre el fondo global y varias estimaciones locales del control; FRiP, la lista negra de ENCODE e IDR evalúan la señal y la reproducibilidad.
- ATAC-seq mide la accesibilidad con Tn5; un buen experimento muestra fragmentos libres de nucleosomas, jorobas nucleosomales, periodicidad helicoidal y un fuerte enriquecimiento en el TSS. CUT&RUN reduce el fondo llevando la nucleasa al factor.
- El bisulfito convierte C no metiladas en T; Bismark alinea en un alfabeto reducido. La metilación es una proporción (β), su logit es el valor M , y la comparación entre grupos requiere un modelo beta-binomial que incluya la variación biológica.
- El descubrimiento de motivos se formula como un problema de datos incompletos: EM (MEME) y muestreo de Gibbs aprenden a la vez la PWM y las posiciones; el enriquecimiento diferencial (HOMER) y la centralidad (CentriMo) identifican los factores responsables.

Ejercicios

Dificultad: ●●● básica ●●● intermedia ●●● avanzada

- 13.1** ●●● Una lectura de 50 pb de la hebra – tiene su extremo 5' en la coordenada 10 480. Si el tamaño de fragmento estimado es $d = 180$, ¿en qué coordenada colocaría el centro del fragmento? ¿Y si la lectura fuera de la hebra + con extremo 5' en 10 480?
- 13.2** ●●● Calcule λ_{BG} para un experimento de 3×10^7 lecturas en ratón ($G = 1,87 \times 10^9$) con $d = 150$. ¿Cuántas lecturas en una ventana hacen falta para $p < 10^{-5}$? Compruébelo con `scipy.stats.poisson.sf`.
- 13.3** ●●● Demuestre que, si $M = \log_2 \frac{\beta}{1-\beta}$, entonces $\beta = \frac{2^M}{1+2^M}$, y use el método delta para mostrar que $\text{Var}(\hat{M})$ es mínima en $\beta = 0,5$. ¿Qué valor mínimo toma con $n = 30$ lecturas?
- 13.4** ●●● Simule 10 000 CpG con $\mu = 0,7$, tres réplicas por grupo y cobertura 20, bajo la hipótesis nula (ambos grupos iguales) con $\phi = 0,1$. Aplique la prueba de Wald con $\phi = 0$ y con $\phi = 0,1$. ¿Qué fracción de valores p cae por debajo de 0,05 en cada caso? Relacione el resultado con la ecuación (13.13).
- 13.5** ●●● Modifique `em_oops` para el modelo ZOOPS añadiendo, para cada secuencia, un estado “sin sitio” con probabilidad a priori $1 - \gamma$. Escriba el paso E y el paso M para γ .
- 13.6** ●●● Implemente el muestreador de Gibbs de las ecuaciones (13.18) y (13.19) y añada un movimiento de desfase que proponga desplazar todas las posiciones ± 1 y lo acepte según la razón de verosimilitudes. Compare, con 20 cadenas, la fracción que alcanza el motivo correcto con y sin ese movimiento.
- 13.7** ●●● Demuestre la desigualdad que sustenta la monotonía de EM: para cualquier distribución $q(Z)$, $\log P(X | \theta) = \mathcal{L}(q, \theta) + \text{KL}(q \| P(Z | X, \theta))$, donde $\mathcal{L}$ es la cota de Jensen. Deduzca que el paso E anula la divergencia y que el paso M no puede disminuir la verosimilitud.
- 13.8** ●●● Descargue de ENCODE los picos IDR de CTCF en una línea celular, extraiga ± 50 pb alrededor de cada cumbre y ejecute `meme-chip`. ¿Coincide el motivo principal con el perfil MA0139 de JASPAR? ¿Qué fracción de los picos lo contiene y qué muestra el análisis de centralidad?

Referencias del capítulo

- Amemiya, H. M., Kundaje, A., & Boyle, A. P. (2019). The ENCODE blacklist: Identification of problematic regions of the genome. *Scientific Reports*, 9(1), 9354. <https://doi.org/10.1038/s41598-019-45839-z>
- Bailey, T. L., Boden, M., Buske, F. A., Frith, M., Grant, C. E., Clementi, L., et al. (2009). MEME SUITE: Tools for motif discovery and searching. *Nucleic Acids Research*, 37(Web Server), W202-W208. <https://doi.org/10.1093/nar/gkp335>
- Bailey, T. L., & Machanick, P. (2012). Inferring direct DNA binding from ChIP-seq. *Nucleic Acids Research*, 40(17), e128. <https://doi.org/10.1093/nar/gks433>
- Bird, A. P. (1986). CpG-rich islands and the function of DNA methylation. *Nature*, 321(6067), 209-213. <https://doi.org/10.1038/321209a0>
- Buenrostro, J. D., Giresi, P. G., Zaba, L. C., Chang, H. Y., & Greenleaf, W. J. (2013). Transposition of native chromatin for fast and sensitive epigenomic profiling of open chromatin, DNA-binding proteins and nucleosome position. *Nature Methods*, 10(12), 1213-1218. <https://doi.org/10.1038/nmeth.2688>
- Buenrostro, J. D., Wu, B., Chang, H. Y., & Greenleaf, W. J. (2015). ATAC-seq: A method for assaying chromatin accessibility genome-wide. *Current Protocols in Molecular Biology*, 109(1), 21.29.1-21.29.9. <https://doi.org/10.1002/0471142727.mb2129s109>
- Castro-Mondragon, J. A., Riudavets-Puig, R., Rauluseviciute, I., Berhanu Lemma, R., Turchi, L., Blanc-Mathieu, R., et al. (2022). JASPAR 2022: The 9th release of the open-access database of transcription factor binding profiles. *Nucleic Acids Research*, 50(D1), D165-D173. <https://doi.org/10.1093/nar/gkab1113>
- Dempster, A. P., Laird, N. M., & Rubin, D. B. (1977). Maximum likelihood from incomplete data via the EM algorithm. *Journal of the Royal Statistical Society: Series B (Methodological)*, 39(1), 1-22. <https://doi.org/10.1111/j.2517-6161.1977.tb01600.x>
- Du, P., Zhang, X., Huang, C.-C., Jafari, N., Kibbe, W. A., Hou, L., et al. (2010). Comparison of Beta-value and M-value methods for quantifying methylation levels by microarray analysis. *BMC Bioinformatics*, 11(1), 587. <https://doi.org/10.1186/1471-2105-11-587>
- ENCODE Project Consortium. (2012). An integrated encyclopedia of DNA elements in the human genome. *Nature*, 489(7414), 57-74. <https://doi.org/10.1038/nature11247>
- ENCODE Project Consortium, Abascal, F., Acosta, R., Addleman, N. J., Adrian, J., Afzal, V., et al. (2020). Expanded encyclopaedias of DNA elements in the human and mouse genomes. *Nature*, 583(7818), 699-710. <https://doi.org/10.1038/s41586-020-2493-4>
- Feng, H., Conneely, K. N., & Wu, H. (2014). A Bayesian hierarchical model to detect differentially methylated loci from single nucleotide resolution sequencing data. *Nucleic Acids Research*, 42(8), e69. <https://doi.org/10.1093/nar/gku154>
- Frommer, M., McDonald, L. E., Millar, D. S., Collis, C. M., Watt, F., Grigg, G. W., et al. (1992). A genomic sequencing protocol that yields a positive display of 5-methylcytosine

- residues in individual DNA strands. *Proceedings of the National Academy of Sciences*, 89(5), 1827-1831. <https://doi.org/10.1073/pnas.89.5.1827>
- Gardiner-Garden, M., & Frommer, M. (1987). CpG islands in vertebrate genomes. *Journal of Molecular Biology*, 196(2), 261-282. [https://doi.org/10.1016/0022-2836\(87\)90689-9](https://doi.org/10.1016/0022-2836(87)90689-9)
- Heinz, S., Benner, C., Spann, N., Bertolino, E., Lin, Y. C., Laslo, P., et al. (2010). Simple combinations of lineage-determining transcription factors prime cis-regulatory elements required for macrophage and B cell identities. *Molecular Cell*, 38(4), 576-589. <https://doi.org/10.1016/j.molcel.2010.05.004>
- Horvath, S. (2013). DNA methylation age of human tissues and cell types. *Genome Biology*, 14(10), R115. <https://doi.org/10.1186/gb-2013-14-10-r115>
- Jenuwein, T., & Allis, C. D. (2001). Translating the histone code. *Science*, 293(5532), 1074-1080. <https://doi.org/10.1126/science.1063127>
- Johnson, D. S., Mortazavi, A., Myers, R. M., & Wold, B. (2007). Genome-wide mapping of in vivo protein-DNA interactions. *Science*, 316(5830), 1497-1502. <https://doi.org/10.1126/science.1141319>
- Kharchenko, P. V., Tolstorukov, M. Y., & Park, P. J. (2008). Design and analysis of ChIP-seq experiments for DNA-binding proteins. *Nature Biotechnology*, 26(12), 1351-1359. <https://doi.org/10.1038/nbt.1508>
- Krueger, F., & Andrews, S. R. (2011). Bismark: A flexible aligner and methylation caller for Bisulfite-Seq applications. *Bioinformatics*, 27(11), 1571-1572. <https://doi.org/10.1093/bioinformatics/btr167>
- Landt, S. G., Marinov, G. K., Kundaje, A., Kheradpour, P., Pauli, F., Batzoglou, S., et al. (2012). ChIP-seq guidelines and practices of the ENCODE and modENCODE consortia. *Genome Research*, 22(9), 1813-1831. <https://doi.org/10.1101/gr.136184.111>
- Lawrence, C. E., Altschul, S. F., Boguski, M. S., Liu, J. S., Neuwald, A. F., & Wootton, J. C. (1993). Detecting subtle sequence signals: A Gibbs sampling strategy for multiple alignment. *Science*, 262(5131), 208-214. <https://doi.org/10.1126/science.8211139>
- Li, Q., Brown, J. B., Huang, H., & Bickel, P. J. (2011). Measuring reproducibility of high-throughput experiments. *The Annals of Applied Statistics*, 5(3), 1752-1779. <https://doi.org/10.1214/11-AOAS466>
- Lister, R., Pelizzola, M., Dowen, R. H., Hawkins, R. D., Hon, G., Tonti-Filippini, J., et al. (2009). Human DNA methylomes at base resolution show widespread epigenomic differences. *Nature*, 462(7271), 315-322. <https://doi.org/10.1038/nature08514>
- Luger, K., Mäder, A. W., Richmond, R. K., Sargent, D. F., & Richmond, T. J. (1997). Crystal structure of the nucleosome core particle at 2.8 Å resolution. *Nature*, 389(6648), 251-260. <https://doi.org/10.1038/38444>
- Park, P. J. (2009). ChIP-seq: Advantages and challenges of a maturing technology. *Nature Reviews Genetics*, 10(10), 669-680. <https://doi.org/10.1038/nrg2641>

- Roadmap Epigenomics Consortium, Kundaje, A., Meuleman, W., Ernst, J., Bilenky, M., Yen, A., et al. (2015). Integrative analysis of 111 reference human epigenomes. *Nature*, 518(7539), 317-330. <https://doi.org/10.1038/nature14248>
- Simpson, J. T., Workman, R. E., Zuzarte, P. C., David, M., Dursi, L. J., & Timp, W. (2017). Detecting DNA cytosine methylation using nanopore sequencing. *Nature Methods*, 14(4), 407-410. <https://doi.org/10.1038/nmeth.4184>
- Skene, P. J., & Henikoff, S. (2017). An efficient targeted nuclease strategy for high-resolution mapping of DNA binding sites. *eLife*, 6, e21856. <https://doi.org/10.7554/eLife.21856>
- Zhang, Y., Liu, T., Meyer, C. A., Eeckhoute, J., Johnson, D. S., Bernstein, B. E., et al. (2008). Model-based analysis of ChIP-Seq (MACS). *Genome Biology*, 9(9), R137. <https://doi.org/10.1186/gb-2008-9-9-r137>